

**BỘ NÔNG NGHIỆP VÀ MÔI TRƯỜNG
PHÂN HIỆU TRƯỜNG ĐẠI HỌC THỦY LỢI
BỘ MÔN CÔNG NGHỆ THÔNG TIN**



BÁO CÁO ĐỒ ÁN

**TÊN ĐỀ TÀI: XÂY DỰNG VÀ ĐÁNH GIÁ MÔ HÌNH HỌC SÂU
CHO DỰ BÁO CHUỖI THỜI GIAN LƯU LƯỢNG MẠNG ISP**

Giảng viên:	TS. Hoàng Văn Quý
Sinh viên thực hiện:	2351267275 - Nguyễn Văn Tấn Phát 2351267280 – Đoàn Anh Vũ 2351267273 – Nguyễn Hồng Nguyên
Lớp:	S26-65TTNT

TP. Hồ Chí Minh, ngày ... tháng ... năm 2026

[illegible]

Chữ ký của giảng viên

LỜI CAM ĐOAN

Tôi xin cam đoan báo cáo này được thực hiện trên cơ sở nghiên cứu tài liệu, xử lý dữ liệu và thực nghiệm mô hình trong phạm vi đề tài. Các bảng biểu, hình minh họa và kết quả được tổng hợp từ quá trình phân tích CESNET-TimeSeries24 và các thực nghiệm kèm theo.

Tài liệu tham khảo được liệt kê ở cuối báo cáo; các nhận định được trình bày theo phạm vi dữ liệu, phương pháp và kết quả thực nghiệm của đề tài.

Sinh viên thực hiện
(Ký và ghi rõ họ tên)

LỜI CẢM ƠN

Tôi xin gửi lời cảm ơn đến giảng viên hướng dẫn vì các góp ý trong quá trình lựa chọn đề tài, xác định phạm vi dữ liệu và hoàn thiện báo cáo. Tôi cũng xin cảm ơn các tác giả công bố CESNET-TimeSeries24 và các công trình liên quan vì nguồn dữ liệu, giao thức đánh giá và mã nguồn tham khảo có khả năng kiểm tra lại.

Tôi xin cảm ơn gia đình, bạn bè và các cá nhân đã hỗ trợ trong quá trình thu thập tài liệu, tổ chức thực nghiệm và rà soát báo cáo.

TÓM TẮT

Báo cáo trình bày bài toán dự báo chuỗi thời gian lưu lượng mạng ISP trên bộ dữ liệu CESNET-TimeSeries24. Phạm vi chính là cấp tổ chức ở độ phân giải một giờ, với hai mốc dự báo 24 giờ và 168 giờ; cấp mạng con được dùng làm thiết lập phụ. Nội dung tập trung vào quan hệ giữa EDA, tiền xử lý và đánh giá ISPNet so với baseline cổ điển, học sâu.

Quy trình gồm EDA, observed_mask cho điểm khuyết, log1p, chuẩn hóa theo thực thể và đánh giá ba seed. ISPNet dùng GRU encoder-decoder hidden=64, RevIN có xét mặt nạ quan sát và entity bias. RevIN trong notebook không có tham số học được, nên số tham số chính tương đương GRU cùng cấu hình.

ISPNet có SMAPE median thấp hơn baseline gần nhất trên bốn thiết lập. Ở cấp tổ chức, SMAPE median là 62,39% cho 24 giờ và 69,35% cho 168 giờ. Ở cấp mạng con, các giá trị tương ứng là 58,81% và 65,85%. Giai đoạn outage 20/05/2024-10/06/2024 được tách riêng do phân phối khác với phần test còn lại.

Từ khóa: dự báo lưu lượng mạng, CESNET-TimeSeries24, chuỗi thời gian, GRU, RevIN, mask-aware learning.

MỤC LỤC

LỜI CAM ĐOAN	2
LỜI CẢM ƠN.....	3
TÓM TẮT.....	4
DANH MỤC CÁC TỪ VIẾT TẮT	7
DANH MỤC BẢNG BIỂU	9
DANH MỤC CÁC HÌNH	10
MỞ ĐẦU	11
1. Tính cấp thiết của đề tài	11
2. Mục tiêu nghiên cứu.....	11
3. Phạm vi nghiên cứu.....	11
4. Phương pháp nghiên cứu.....	11
5. Bố cục báo cáo	12
CHƯƠNG 1. TỔNG QUAN NGHIÊN CỨU VÀ CƠ SỞ LỰA CHỌN MÔ HÌNH ...	13
1.1. Bài toán dự báo lưu lượng mạng ISP	13
1.2. Các hướng tiếp cận dự báo chuỗi thời gian lưu lượng	13
1.3. Các công trình nền tảng trực tiếp của đề tài.....	14
1.4. Cơ sở lựa chọn cấu hình ISPNet	14
CHƯƠNG 2. DỮ LIỆU, TIỀN XỬ LÝ VÀ XÂY DỰNG MÔ HÌNH	15
2.1. Dữ liệu và phát biểu bài toán	15
2.2. Cơ sở lựa chọn phạm vi dữ liệu	15
2.3. Quy trình tiền xử lý	16
2.4. Phân tích đặc tính chuỗi thời gian.....	17
2.5. Thiết kế đặc trưng và mô hình	21
CHƯƠNG 3. THỰC NGHIỆM VÀ ĐÁNH GIÁ	25
3.1. Giao thức thực nghiệm.....	25
3.2. Tham số mô hình và thời gian huấn luyện.....	25
3.3. Chỉ số đánh giá.....	27
3.4. Kết quả baseline cổ điển	27

3.5. Kết quả mô hình học sâu và ISPNet	27
3.6. Đối chiếu trực tiếp với baseline gần nhất.....	30
3.7. Đối chiếu benchmark và chi phí triển khai	32
3.8. Ablation thành phần ISPNet.....	33
3.9. Phân tích giai đoạn outage	34
3.10. Hạn chế và hướng phát triển	34
KẾT LUẬN	36
TÀI LIỆU THAM KHẢO	37

DANH MỤC CÁC TỪ VIẾT TẮT

Từ viết tắt	Tiếng Anh	Diễn giải
ACF	Autocorrelation Function	Hàm tự tương quan
GRU	Gated Recurrent Unit	Đơn vị hồi quy có cổng
ISP	Internet Service Provider	Nhà cung cấp dịch vụ Internet
PACF	Partial Autocorrelation Function	Hàm tự tương quan riêng phần
RevIN	Reversible Instance Normalization	Chuẩn hóa thể hiện đảo ngược
R ²	Coefficient of Determination	Hệ số xác định
SARIMA	Seasonal ARIMA	Mô hình ARIMA có thành phần mùa vụ
SMAPE	Symmetric Mean Absolute Percentage Error	Sai số phần trăm tuyệt đối đối xứng
TS-Zoo	Time-Series Zoo	Thư viện chuẩn hóa xử lý và tái lập thí nghiệm chuỗi thời gian
DLinear	Decomposition Linear Model	Mô hình tuyến tính phân rã cho chuỗi thời gian
EDA	Exploratory Data Analysis	Phân tích khám phá dữ liệu
FFT	Fast Fourier Transform	Biến đổi Fourier nhanh
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
LSTM	Long Short-Term Memory	Mạng bộ nhớ dài-ngắn hạn
MA	Moving Average	Trung bình trượt
MAPE	Mean Absolute Percentage Error	Sai số phần trăm tuyệt đối trung bình
RMSE	Root Mean Squared Error	Căn bậc hai sai số bình phương trung bình
SN	Seasonal Naive	Dự báo mùa vụ lặp lại

Từ viết tắt	Tiếng Anh	Diễn giải
TCN	Temporal Convolutional Network	Mạng tích chập theo thời gian
VRAM	Video Random Access Memory	Bộ nhớ đồ họa
KAN	Kolmogorov-Arnold Network	Mạng Kolmogorov-Arnold

DANH MỤC BẢNG BIỂU

Bảng 1.1. Các công trình nền tảng trực tiếp của đề tài.....	14
Bảng 2.1. Thông tin tổng quan dữ liệu CESNET-TimeSeries24	15
Bảng 2.2. Cơ sở lựa chọn phạm vi dữ liệu	15
Bảng 2.3. Cấu hình tiền xử lý và chia tập dữ liệu	16
Bảng 2.4. Ma trận bằng chứng EDA cho các quyết định tiền xử lý.....	20
Bảng 2.5. So sánh lựa chọn xử lý với phương án khác	21
Bảng 2.6. Tóm tắt kiến trúc ISPNet	23
Bảng 3.1. Giao thức đánh giá và quy mô cửa sổ	25
Bảng 3.2. Tham số mô hình và thời gian huấn luyện theo track thực nghiệm.....	25
Bảng 3.3. Kết quả baseline cổ điển theo cấp dữ liệu.....	27
Bảng 3.4. Kết quả mô hình học sâu và ISPNet ở cấp tổ chức, horizon 24 giờ	27
Bảng 3.5. Kết quả mô hình học sâu và ISPNet ở cấp tổ chức, horizon 168 giờ	29
Bảng 3.6. Kết quả mô hình học sâu và ISPNet ở cấp mạng con, horizon 24 giờ	29
Bảng 3.7. Kết quả mô hình học sâu và ISPNet ở cấp mạng con, horizon 168 giờ	30
Bảng 3.8. Chênh lệch giữa ISPNet và baseline học sâu gần nhất	30
Bảng 3.9. Phân tích theo nhóm thực thể so với baseline gần nhất	32
Bảng 3.10. Đối chiếu benchmark và độ phức tạp chính.....	32
Bảng 3.11. Ablation thành phần ISPNet trên track tổ chức, horizon 24 giờ.....	33
Bảng 3.12. Phân tích giai đoạn outage của ISPNet	34

DANH MỤC CÁC HÌNH

Hình 2.1. Quy trình tiền xử lý và tổ chức dữ liệu đầu vào	17
Hình 2.2. Diễn biến tổng lưu lượng n_bytes theo thời gian ở cấp tổ chức	17
Hình 2.3. Phân phối lưu lượng và tác động của biến đổi logarit.....	18
Hình 2.4. Chênh lệch quy mô giữa các institution	18
Hình 2.5. Chu kỳ ngày và tuần trong chuỗi lưu lượng.....	18
Hình 2.6. Mẫu khuyết dữ liệu và cửa sổ outage	19
Hình 2.7. Tác động lịch, xu hướng trung vị cuộn và ví dụ thay đổi mức nền.....	20
Hình 2.8. Vai trò của học có mặt nạ quan sát.....	22
Hình 2.9. Kiến trúc tổng quát của mô hình ISPNet.....	22
Hình 3.1. So sánh SMAPE median giữa baseline gần nhất và ISPNet	31

MỞ ĐẦU

1. Tính cấp thiết của đề tài

Dự báo lưu lượng mạng phục vụ lập kế hoạch băng thông, phân bổ tài nguyên và theo dõi trạng thái vận hành ISP. Dữ liệu thực tế thường có phân phối lệch, chênh lệch quy mô giữa nhóm người dùng, biến động theo lịch và khoảng khuyết do telemetry.

CESNET-TimeSeries24 được chọn vì dữ liệu xuất phát từ hệ thống mạng đang vận hành. Ở cấp tổ chức và độ phân giải một giờ, dữ liệu gồm 283 chuỗi, 6.718 mốc thời gian, hơn 1,88 triệu dòng quan sát và 1,11% điểm khuyết. Các đặc điểm này yêu cầu tiền xử lý phân biệt điểm khuyết với lưu lượng bằng không.

Từ các đặc tính trên, báo cáo khảo sát ISPNet, một biến thể GRU có chuẩn hóa động theo cửa sổ, học có mặt nạ quan sát và đặc trưng chu kỳ lịch. Trọng tâm là liên kết EDA với quyết định tiền xử lý và thiết kế mô hình.

2. Mục tiêu nghiên cứu

- Phân tích các đặc tính chuỗi thời gian của CESNET-TimeSeries24 ở cấp tổ chức và độ phân giải một giờ.
- Thiết lập quy trình tiền xử lý phân biệt giữa thiếu telemetry và lưu lượng bằng không, đồng thời hạn chế rò rỉ dữ liệu giữa các tập.
- Thiết lập baseline cổ điển và baseline học sâu trong cùng giao thức chia tập theo thời gian.
- Thiết lập và đánh giá mô hình ISPNet dựa trên GRU, chuẩn hóa động theo cửa sổ, mặt nạ quan sát, đặc trưng lịch và thành phần bù theo từng tổ chức.
- Đánh giá kết quả bằng sai số tương đối đối xứng, hệ số xác định và phân tích theo các lát cắt có liên quan đến outage hoặc thay đổi phân phối.

3. Phạm vi nghiên cứu

Báo cáo dùng cấp tổ chức ở độ phân giải một giờ làm phạm vi chính; biến mục tiêu là lưu lượng byte theo giờ. Cấp mạng con là thiết lập phụ để kiểm tra xu hướng khi số chuỗi tăng từ 283 lên 546 và tỷ lệ khuyết cao hơn. Cấp IP và dự báo đa mục tiêu chưa đưa vào thực nghiệm chính do độ thừa và yêu cầu tài nguyên.

4. Phương pháp nghiên cứu

Quy trình gồm bốn phần: khảo sát tài liệu và benchmark CESNET-TimeSeries24; EDA để xác định đặc tính dữ liệu; thiết lập baseline cổ điển, baseline học sâu và ISPNet; đánh giá trên tập kiểm thử theo từng thực thể, sau đó tổng hợp bằng median/mean.

5. Bố cục báo cáo

Báo cáo gồm ba chương ngoài mở đầu, kết luận và tài liệu tham khảo. Chương 1 trình bày bối cảnh và cơ sở lựa chọn mô hình. Chương 2 mô tả dữ liệu, tiền xử lý và thiết kế ISPNet. Chương 3 trình bày thực nghiệm, đối sánh và phạm vi áp dụng.

CHƯƠNG 1. TỔNG QUAN NGHIÊN CỨU VÀ CƠ SỞ LỰA CHỌN MÔ HÌNH

1.1. Bài toán dự báo lưu lượng mạng ISP

Dự báo lưu lượng mạng ISP được phát biểu như bài toán dự báo đa bước. Với mỗi tổ chức, mô hình dùng cửa sổ quá khứ để dự báo hai mốc 24 giờ và 168 giờ; mốc 24 giờ gắn với vận hành theo ngày, còn 168 giờ gắn với chu kỳ tuần.

Lưu lượng mạng biến động theo giờ, ngày trong tuần, cuối tuần, ngày nghỉ và trạng thái đo đạc. Vì vậy, mô hình cần tiếp nhận lịch sử lưu lượng, tín hiệu lịch và trạng thái quan sát của dữ liệu.

1.2. Các hướng tiếp cận dự báo chuỗi thời gian lưu lượng

Nhóm cổ điển gồm Mean, Seasonal Naive, Moving Average và SARIMA. Nhóm này tạo mốc so sánh có thể kiểm tra, nhưng bị giới hạn khi dữ liệu có khoảng khuyết, lịch, mức nền riêng theo tổ chức và quan hệ phi tuyến.

Nhóm học sâu gồm LSTM, GRU, TCN, DLinear, Transformer, PatchTST và iTransformer. Các mô hình này tiếp nhận nhiều đặc trưng đầu vào và được dùng làm baseline cho ISPNet trong cùng giao thức dữ liệu.

LSTM và GRU là nhóm recurrent có cơ chế công theo thời gian [6], [8]. GRU được giữ làm baseline gần nhất vì ISPNet dùng encoder-decoder GRU; phần chênh lệch chủ yếu nằm ở chuẩn hóa động và mặt nạ quan sát.

TCN dùng tích chập nhân quả và dilation để mở rộng receptive field [10]. Trong dữ liệu ISP, mức nền thay đổi, missing và outage làm mẫu cục bộ không lặp lại đều; vì vậy TCN được dùng như baseline học biểu diễn.

DLinear tách xu hướng và mùa vụ rồi dùng ánh xạ tuyến tính [11]. Với CESNET-TimeSeries24, phân phối đuôi nặng, outage và mức nền thay đổi theo thực thể làm thiết lập tuyến tính khó bao quát mốc 168 giờ.

Transformer, PatchTST và iTransformer đại diện cho nhóm attention [9], [12], [13]. Trong phạm vi này, mỗi thực thể được dự báo chủ yếu từ lịch sử riêng và đặc trưng lịch; nếu thiếu mặt nạ phù hợp, cơ chế patching có thể làm mờ gap hoặc outage.

Các baseline học sâu được dùng để kiểm tra giả định về phụ thuộc thời gian: recurrence, convolution, linear decomposition và attention. Kết quả Chương 3 được đọc theo các giả định này thay vì chỉ theo từng giá trị SMAPE.

1.3. Các công trình nền tảng trực tiếp của đề tài

Bảng 1.1. Các công trình nền tảng trực tiếp của đề tài

Công trình	Vai trò đối với đề tài	Cách sử dụng trong báo cáo
Benchmark học sâu cho dự báo lưu lượng ISP năm 2025	Cung cấp giao thức chia tập theo thời gian 14/2/24 tuần và nhóm backbone học sâu trên CESNET-TimeSeries24.	Dùng làm cơ sở đối sánh và kế thừa tinh thần đánh giá theo thời gian.
Thư viện TS-Zoo cho phân tích chuỗi lưu lượng mạng	Định hình nhu cầu chuẩn hóa truy cập dữ liệu, xử lý khoảng khuyết và tái lập thí nghiệm.	Dùng làm tham chiếu cho cách tổ chức pipeline tiền xử lý và thực nghiệm.
Nghiên cứu mô hình nền móng chuỗi thời gian cho ISP	Đưa hướng zero-shot và few-shot vào bối cảnh dự báo lưu lượng ISP.	Dùng để xác định hướng mở rộng, chưa đưa vào nhóm thực nghiệm chính.
Bài báo công bố CESNET-TimeSeries24	Mô tả nguồn dữ liệu thực tế, cấu trúc phân cấp và quy mô dòng mạng.	Dùng làm nguồn dữ liệu nền và cơ sở lựa chọn cấp tổ chức làm phạm vi chính.

Các công trình liên quan cung cấp ba điểm tựa: dữ liệu thực, giao thức đánh giá và nhóm baseline. Phần riêng của báo cáo nằm ở biện giải tiền xử lý và ISPNet theo phân phối đuôi nặng, khoảng khuyết, chênh lệch quy mô và thay đổi mức nền.

1.4. Cơ sở lựa chọn cấu hình ISPNet

Benchmark diện rộng phù hợp cho so sánh nhiều backbone. Trong phạm vi đồ án và tài nguyên đơn GPU, câu hỏi nghiên cứu tập trung vào cách đặc tính dữ liệu được phản ánh trong tiền xử lý và mô hình.

ISPNet giữ GRU encoder-decoder làm backbone, kết hợp chuẩn hóa động theo cửa sổ và mặt nạ quan sát. Cấu hình này thuận lợi khi đối chiếu với GRU baseline vì số tham số và cấu trúc chính gần tương đương.

Kết luận chương 1: Chương 1 trình bày bối cảnh, công trình liên quan, nhóm baseline học sâu và cơ sở lựa chọn ISPNet. Mô hình được hình thành từ đặc tính dữ liệu và yêu cầu thực nghiệm của đề tài.

CHƯƠNG 2. DỮ LIỆU, TIỀN XỬ LÝ VÀ XÂY DỰNG MÔ HÌNH

2.1. Dữ liệu và phát biểu bài toán

Dữ liệu thực nghiệm là CESNET-TimeSeries24 ở cấp tổ chức, độ phân giải một giờ. Báo cáo xét hai thiết lập: 168 giờ quá khứ dự báo 24 giờ kế tiếp và 744 giờ quá khứ dự báo 168 giờ kế tiếp. Chỉ các điểm có quan sát thật được dùng khi đánh giá.

Bảng 2.1. Thông tin tổng quan dữ liệu CESNET-TimeSeries24

Thuộc tính	Giá trị
Cấp dữ liệu chính	Tổ chức
Số chuỗi thời gian	283 tổ chức
Số mốc thời gian	6.718 mốc theo giờ
Khoảng thời gian	09/10/2023 00:00 UTC đến 14/07/2024 21:00 UTC
Biến dự báo	Lưu lượng byte truyền qua trong mỗi giờ
Dòng quan sát	1.880.182 / 1.901.194, đạt 98,89%
Dòng khuyết	21.012, tương ứng 1,11%
Cửa sổ outage	20/05/2024 đến 10/06/2024, tổng cộng 528 giờ

2.2. Cơ sở lựa chọn phạm vi dữ liệu

Bảng 2.2. Cơ sở lựa chọn phạm vi dữ liệu

Phạm vi	Cơ sở dữ liệu/vận hành	Quyết định trong báo cáo
Cấp tổ chức	Số chuỗi vừa phải, tỷ lệ khuyết trung bình thấp và gắn với bài toán vận hành cấp đơn vị.	Được chọn làm track chính.
Cấp mạng con	Chi tiết hơn cấp tổ chức, số chuỗi tăng lên 546 và tỷ lệ khuyết trung bình cao hơn.	Được sử dụng làm track phụ để kiểm tra xu hướng kết quả khi phạm vi dữ liệu chi tiết hơn.
Cấp IP	Độ thưa cao và cần cơ chế lấy mẫu riêng.	Chưa đưa vào thực nghiệm học sâu chính.

Phạm vi	Cơ sở dữ liệu/vận hành	Quyết định trong báo cáo
Lưu lượng byte	Phản ánh dung lượng truyền tải và liên quan đến lập kế hoạch băng thông.	Được chọn làm biến dự báo.
Độ phân giải một giờ	Cân bằng giữa độ chi tiết vận hành và độ ổn định của tín hiệu chuỗi thời gian.	Được dùng trong toàn bộ pipeline.

Phạm vi được giới hạn để phân tích tác động của tiền xử lý và chuẩn hóa động trên thiết lập có tỷ lệ quan sát cao, đồng thời phù hợp với môi trường huấn luyện đơn GPU.


2.3. Quy trình tiền xử lý

Tiền xử lý dựa trên bảng chứng EDA. Dữ liệu được đưa về cùng trục thời gian theo giờ; vị trí không có dòng gốc được đánh dấu bằng `observed_mask` và không được quy đổi thành lưu lượng bằng không.

Các cột đếm được biến đổi $\log_{1p}$ trước khi chuẩn hóa. Bộ chuẩn hóa fit riêng theo từng thực thể trên tập huấn luyện; đặc trưng lịch, độ dài gap và cờ bắt đầu gap được đưa vào để mô hình nhận ngữ cảnh quan sát.

Bảng 2.3. Cấu hình tiền xử lý và chia tập dữ liệu

Thành phần	Thiết lập
Tần suất dữ liệu	Một giờ
Chia tập	14 tuần huấn luyện, 2 tuần validation, 24 tuần kiểm thử
Biến đổi mục tiêu	Biến đổi logarit trước khi chuẩn hóa
Bộ chuẩn hóa	Chuẩn hóa bền vững theo từng tổ chức, fit trên tập huấn luyện
Điểm khuyết	Giữ mặt nạ quan sát, không đưa điểm khuyết vào hàm mất mát
Đặc trưng lịch	Giờ trong ngày, ngày trong tuần, cuối tuần và ngày nghỉ
Đặc trưng khoảng khuyết	Độ dài khoảng khuyết và dấu hiệu bắt đầu khoảng khuyết




Hình 2.1. Quy trình tiền xử lý và tổ chức dữ liệu đầu vào

Sơ đồ mô tả luồng xử lý từ dữ liệu đầu vào đến `observed_mask`, đặc trưng lịch/gap, `log1p`, chuẩn hóa trên train-only, kiểm tra dữ liệu và tạo đầu vào mô hình.

2.4. Phân tích đặc tính chuỗi thời gian

EDA được dùng như ma trận bằng chứng cho tiền xử lý. Các đặc tính chính gồm phân phối đuôi nặng, chênh lệch quy mô, missing telemetry, outage, chu kỳ ngày/tuần, tác động lịch và thay đổi mức nền.

Figure 1 — Raw traffic is extremely skewed; log1p restores near-normality




Hình 2.2. Diễn biến tổng lưu lượng n_bytes theo thời gian ở cấp tổ chức

Biểu đồ thể hiện tổng lưu lượng theo giờ trên thang logarit, trung vị cuộn 168 giờ, ranh giới train/validation/test và vùng outage trong tập kiểm thử.

Hình 2.3. Phân phối lưu lượng và tác động của biến đổi logarit

Biểu đồ gồm phân phối gốc, phân phối sau $\log_{1p}$ và $Q-Q$ plot; $\log_{1p}$ làm giảm độ lệch phải của dữ liệu.


Lưu lượng gốc có median khoảng 98 MB/giờ, mean khoảng 2.166 MB/giờ và giá trị lớn nhất khoảng 1.023 GB/giờ. Skew giảm từ 11,92 xuống -0,81 sau $\log_{1p}$, với kurtosis khoảng 0,70; do đó $\log_{1p}$ được dùng trước chuẩn hóa và huấn luyện.



Hình 2.4. Chênh lệch quy mô giữa các institution

Biểu đồ thể hiện khác biệt quy mô giữa 283 tổ chức trên thang logarit và độ biến động nội bộ theo từng tổ chức.

Median lưu lượng giữa các tổ chức chênh khoảng $8,26e7$ lần. Chuẩn hóa toàn cục có thể nén nhóm lưu lượng nhỏ, nên báo cáo dùng chuẩn hóa theo từng tổ chức để giữ biến động cục bộ.




Hình 2.5. Chu kỳ ngày và tuần trong chuỗi lưu lượng

Biểu đồ ACF và phổ tần cho thấy hai chu kỳ chính tại 24 giờ và 168 giờ.


Tự tương quan trung bình khoảng 0,48 ở lag 24 giờ và 0,46 ở lag 168 giờ; FFT cũng có đỉnh tại 24 giờ và 168 giờ. Vì vậy, mốc 24 giờ đại diện cho ngắn hạn theo ngày, còn 168 giờ đại diện cho chu kỳ tuần.

Figure 4 — Missing patterns: entity-level gaps + system-wide outage window



Hình 2.6. Mẫu khuyết dữ liệu và cửa sổ outage

Ở cấp tổ chức, tỷ lệ khuyết trung bình là 1,11%, mức khuyết cực đại theo chuỗi là 86,57%. EDA ghi nhận 2.540 sự kiện gap, gap 1 giờ chiếm 62,2%, gap dài nhất 2.241 giờ; cửa sổ outage trong test kéo dài 528 giờ. Do đó, điểm thiếu được giữ bằng mặt nạ quan sát và outage được tách khi diễn giải.



Hình 2.7. Tác động lịch, xu hướng trung vị cuộn và ví dụ thay đổi mức nền

Hình thể hiện lưu lượng cuối tuần/ngày nghỉ thấp hơn ngày thường, trung vị cuộn 168 giờ thay đổi theo thời gian và một số chuỗi có đổi mức nền trong test.

Bảng 2.4. Ma trận bằng chứng EDA cho các quyết định tiền xử lý

Nhận định tiền xử lý	Bảng chứng EDA định lượng	Rủi ro nếu bỏ qua	Quyết định áp dụng
Phân phối n_bytes đuôi nặng	median 98,4 MB/h; mean 2.165,8 MB/h; skew gốc 11,92; log1p skew -0,81, kurtosis 0,70	Sai số chịu ảnh hưởng lớn từ cực trị; học trên thang gốc có độ ổn định thấp hơn	Dùng log1p trước chuẩn hóa và huấn luyện
Quy mô thực thể khác nhau nhiều bậc	median traffic từ 974 đến 8,044e10; chênh 8,26e7 lần; median CV 1,68	Scaler toàn cục làm nhóm lưu lượng nhỏ bị nén, tín hiệu cục bộ kém ổn định	RobustScaler theo từng thực thể, fit trên train-only
Thiếu telemetry không đồng nghĩa lưu lượng bằng 0	missing trung bình 1,11%; max 86,57%; 2.540 gap events; max gap 2.241h	Zero-fill tạo mục tiêu giả và kéo lệch thống kê cửa sổ	observed_mask, gap_since_last_obs, is_gap_start; loss chỉ tính điểm quan sát
Có outage trong tập kiểm thử	20/05/2024-10/06/2024; 528 giờ; nằm trong test	Kết quả tổng thể có thể che khuất lát cắt có phân phối khác biệt	Tách outage khi đánh giá và diễn giải kết quả
Chu kỳ ngày và tuần có trong EDA	ACF lag-24 = 0,482; lag-168 = 0,457; seasonal strength = 0,885	Cửa sổ quá ngắn không bao phủ mùa vụ tuần	Encoder 168h; đặc trưng sin/cos giờ và thứ; lag24/lag168
Lịch làm thay đổi hành vi mạng	Weekend thấp hơn weekday 26,6%; holiday thấp hơn normal 22,4%	Mô hình chỉ nhìn quá khứ thiếu tín hiệu ngoại sinh	Sử dụng is_weekend, is_holiday và đặc trưng lịch liên tục
Mức nền thay đổi theo thời gian	trend strength 0,674; slope median -0,0398 log1p/tuần; 93,3% chuỗi có xu hướng giảm trong train	Chuẩn hóa tĩnh có mức thích ứng thấp với nền cục bộ	RevIN/mask-aware window normalization trong ISPNet

Nhận định tiền xử lý	Bảng chứng EDA định lượng	Rủi ro nếu bỏ qua	Quyết định áp dụng
Chọn track chính	institution missing 1,11%; subnet 3,82%; IP sample 79,03%	Cấp IP có độ thừa cao so với phạm vi đồ án đơn GPU	Cấp tổ chức là track chính; cấp mạng con là track phụ


Bảng 2.5. So sánh lựa chọn xử lý với phương án khác

Phương án không dùng làm thiết lập chính	Cơ sở giới hạn	Thiết lập được dùng
Dùng lưu lượng ban đầu	Phân phối lệch và có điểm cực trị lớn.	Biến đổi logarit và chuẩn hóa trước huấn luyện.
Chuẩn hóa toàn cục	Chênh lệch quy mô giữa các tổ chức làm giảm độ phân giải của tổ chức nhỏ.	Chuẩn hóa bền vững theo từng tổ chức.
Xem điểm khuyết là lưu lượng bằng không	Thiếu telemetry không đồng nghĩa với không có lưu lượng.	Dùng mặt nạ quan sát trong chuẩn hóa và hàm mất mát.
Chọn cấp IP làm phạm vi chính	Độ thừa và số lượng chuỗi cao hơn, cần cơ chế lấy mẫu riêng.	Chọn cấp tổ chức làm track chính.
Chỉ dùng baseline mùa vụ	Baseline mùa vụ phản ánh chu kỳ nhưng hệ số xác định vẫn còn hạn chế.	Kết hợp nhóm học sâu có đặc trưng lịch và mùa vụ.
Chọn Transformer làm mô hình ISPNet chính	Kết quả có SMAPE thấp nhưng số tham số cao hơn; mục tiêu chính là kiểm tra tác động chuẩn hóa động trên backbone gọn.	Giữ GRU kết hợp chuẩn hóa động có mặt nạ.

2.5. Thiết kế đặc trưng và mô hình

Đầu vào mô hình gồm ba nhóm: lưu lượng đã xử lý kèm tín hiệu điểm khuyết; đặc trưng lịch; neo mùa vụ từ cùng giờ của ngày trước và tuần trước. Với mốc 168 giờ, lag24 không đưa vào decoder để tránh dùng thông tin thuộc vùng dự báo; decoder giữ đặc trưng lịch và lag168.


Figure 8 — Zero-fill bias: mask-aware loss restricts gradient to observed positions



Hình 2.8. Vai trò của học có mặt nạ quan sát

Hình minh họa khác biệt giữa zero-fill và học có mặt nạ; loss chỉ tính trên vị trí có dữ liệu thật.

ISPNet dùng encoder-decoder GRU kết hợp chuẩn hóa động theo cửa sổ. Thống kê chuẩn hóa được tính trên điểm quan sát thật; dự báo sau đó được đưa về thang đo ban đầu và cộng thành phần bù theo từng tổ chức.



Hình 2.9. Kiến trúc tổng quát của mô hình ISPNet

Sơ đồ mô tả encoder, decoder, tiền xử lý theo mặt nạ, GRU encoder-decoder, đầu dự đoán, giải chuẩn hóa và entity bias cho không gian dự báo 24 bước.

Với cửa sổ đầu vào $X = [x_1, x_2, \dots, x_L]$ và mặt nạ $M = [m_1, m_2, \dots, m_L]$, trong đó $m_t = 1$ nếu có quan sát và $m_t = 0$ nếu khuyết, trung bình và phương sai được tính trên các điểm quan sát thật:

$$\mu = \frac{\sum_{t=1}^L m_t x_t}{\sum_{t=1}^L m_t + \epsilon}$$

$$\sigma^2 = \frac{\sum_{t=1}^L m_t (x_t - \mu)^2}{\sum_{t=1}^L m_t + \varepsilon}$$

Trong đó $\varepsilon = 10^{-5}$ để tránh chia cho 0. Chuỗi sau chuẩn hóa được đưa vào GRU theo công thức:

$$\bar{x}_t = \frac{x_t - \mu}{\sqrt{\sigma^2 + \varepsilon}}$$

$$h_t = \text{GRU}([\bar{x}_t, c_t, m_t], h_{t-1}), \quad t = 1, \dots, L$$

Giá trị dự báo trong không gian chuẩn hóa được giải chuẩn hóa về thang logarit trước khi cộng thành phần bù theo từng tổ chức:

$$\hat{z}_{t:t+H-1} = f_\theta(h_L, d_{t:t+H-1})$$

$$\hat{y}_{t+h}^{\log} = \hat{z}_{t+h} \sqrt{\sigma^2 + \varepsilon} + \mu + b_{e,h}, \quad h = 1, \dots, H$$

Cách tính này giữ thống kê chuẩn hóa không bị ảnh hưởng bởi điểm khuyết. Hàm mất mát huấn luyện là Huber có mặt nạ quan sát trên không gian log1p sau chuẩn hóa:

$$r_{t+h} = \hat{y}_{t+h}^{\log} - y_{t+h}^{\log}$$

$$H_\delta(r) = \frac{1}{2}r^2 \quad (|r| \leq \delta), \quad H_\delta(r) = \delta(|r| - \frac{1}{2}\delta) \quad (|r| > \delta)$$

$$\mathcal{L} = \frac{\sum_{h=1}^H m_{t+h} H_\delta(r_{t+h})}{\sum_{h=1}^H m_{t+h} + \varepsilon}$$

Trong thực nghiệm, $m_t = 1$ tại điểm có quan sát thật, $m_t = 0$ tại điểm khuyết và $\delta = 1,0$. Loss này không tạo mục tiêu giả tại vị trí thiếu telemetry. Cấu hình notebook dùng hidden=64; RevIN không có tham số học được, còn entity bias phụ thuộc số thực thể và độ dài horizon.

Bảng 2.6. Tóm tắt kiến trúc ISPNet

Thành phần	Giá trị
Cửa sổ đầu vào	168 giờ cho horizon 24 giờ; 744 giờ cho horizon 168 giờ
Khoảng dự báo	24 giờ và 168 giờ
Backbone	GRU encoder-decoder hai lớp
Số chiều trạng thái ẩn	64

Thành phần	Giá trị
Dropout	0,4
Tối ưu hóa	AdamW, lr=1e-3, weight decay=2e-3, warmup 5 epoch, cosine decay, early stopping patience=10
Hàm mất mát	Huber có mặt nạ quan sát, $\delta = 1,0$
Chuẩn hóa động	RevIN/mask-aware normalization theo cửa sổ; không có tham số học được trong notebook
Thành phần bù theo thực thể	6.792 tham số ở cấp tổ chức, horizon 24 giờ (283×24)
Tổng số tham số	88.009 ở cấp tổ chức, horizon 24 giờ

Ghi chú: Bảng 2.6 mô tả cấu hình chính ở cấp tổ chức, mốc 24 giờ. Với horizon 168 giờ ở cấp tổ chức, entity bias là 47.544 tham số và tổng số tham số là 128.377. Ở cấp mạng con, tổng số tham số là 94.321 cho 24 giờ và 172.561 cho 168 giờ.

Kết luận chương 2: Các lựa chọn tiền xử lý và mô hình được liên kết với EDA. Cấp tổ chức là phạm vi chính; cấp mạng con được dùng ở Chương 3 như lát cắt phụ theo số thực thể.

CHƯƠNG 3. THỰC NGHIỆM VÀ ĐÁNH GIÁ

3.1. Giao thức thực nghiệm

Thực nghiệm chia dữ liệu theo thời gian: 14 tuần huấn luyện, 2 tuần validation và 24 tuần kiểm thử. Chuẩn hóa chỉ fit trên train; validation dùng để chọn mô hình, test dùng cho đánh giá cuối. Kết quả tổng hợp theo từng thực thể bằng median/mean.

Bảng 3.1. Giao thức đánh giá và quy mô cửa sổ

Track	Số thực thể	Input	Horizon	Cửa sổ train/val/test	Vai trò
Tổ chức - ngắn hạn	283	168h	24h	25.753 / 3.962 / 47.261	Track chính
Tổ chức - trung hạn	283	744h	168h	18.961 / 566 / 6.509	Track chính
Mạng con - ngắn hạn	546	168h	24h	49.686 / 7.644 / 91.182	Track phụ
Mạng con - trung hạn	546	744h	168h	36.582 / 1.092 / 12.558	Track phụ

Ở horizon 168 giờ, decoder không dùng lag24 vì một phần giá trị rơi vào vùng dự báo; thiết lập chỉ giữ đặc trưng lịch và lag168 để tránh thông tin tương lai.

3.2. Tham số mô hình và thời gian huấn luyện

Tham số và thời gian huấn luyện được tổng hợp từ thực nghiệm. Thời gian là trung bình ba seed trên GPU T4; cột epoch là thời điểm validation loss dùng để lưu checkpoint theo dừng sớm.

Mean, Seasonal Naive và Moving Average không có tham số học theo gradient. SARIMA fit thống kê theo từng chuỗi nên không đặt cùng bảng với nhóm học sâu.

Bảng 3.2. Tham số mô hình và thời gian huấn luyện theo track thực nghiệm

Track	Mô hình	Số tham số	Epoch chọn TB	Thời gian TB/seed (phút)
Tổ chức, 24h	LSTM	114.377	19,3	1,77
Tổ chức, 24h	GRU	88.009	18,7	1,73
Tổ chức, 24h	TCN	213.984	20,3	4,83
Tổ chức, 24h	DLinear	14.915	14,7	0,97
Tổ chức, 24h	Transformer	241.737	16,0	4,20

Track	Mô hình	Số tham số	Epoch chọn TB	Thời gian TB/seed (phút)
Tổ chức, 24h	PatchTST	133.419	8,0	1,30
Tổ chức, 24h	iTransformer	119.147	13,0	1,67
Tổ chức, 24h	ISPNet	88.009	17,0	1,70
Tổ chức, 168h	LSTM	154.617	60,3	5,07
Tổ chức, 168h	GRU	128.377	57,7	4,60
Tổ chức, 168h	TCN	414.624	19,0	10,80
Tổ chức, 168h	DLinear	297.873	13,3	0,77
Tổ chức, 168h	Transformer	282.361	33,7	35,13
Tổ chức, 168h	PatchTST	498.409	24,7	1,87
Tổ chức, 168h	iTransformer	206.121	13,7	1,40
Tổ chức, 168h	ISPNet	128.377	12,0	1,67
Mạng con, 24h	LSTM	120.689	15,3	3,07
Mạng con, 24h	GRU	94.321	16,3	3,17
Mạng con, 24h	TCN	220.296	16,0	8,07
Mạng con, 24h	DLinear	21.227	13,3	1,87
Mạng con, 24h	Transformer	248.049	13,0	7,30
Mạng con, 24h	PatchTST	139.731	14,7	3,57
Mạng con, 24h	iTransformer	125.459	14,0	3,50
Mạng con, 24h	ISPNet	94.321	13,0	2,87
Mạng con, 168h	LSTM	198.801	43,3	7,57
Mạng con, 168h	GRU	172.561	40,7	6,97
Mạng con, 168h	TCN	458.808	14,0	17,17
Mạng con, 168h	DLinear	342.057	8,3	1,17
Mạng con, 168h	Transformer	326.545	18,3	43,73
Mạng con, 168h	PatchTST	542.593	45,7	6,10
Mạng con, 168h	iTransformer	250.305	12,0	2,37
Mạng con, 168h	ISPNet	172.561	39,3	6,93

Số tham số của ISPNet bằng GRU trong cùng track vì RevIN không có tham số học được. Ở track 168 giờ, entity bias chiếm khoảng 37% tổng tham số, nên thành phần này cần được xem như hiệu chỉnh theo thực thể khi mở rộng sang chuỗi mới hoặc dữ liệu ít quan sát.

Nhóm học sâu dùng Huber loss có mặt nạ quan sát với $\delta = 1,0$. Công thức ở mục 2.5; Chương 3 báo cáo kết quả bằng SMAPE và R^2 trên test.

3.3. Chỉ số đánh giá

SMAPE được dùng cho sai số tương đối vì ổn định hơn MAPE khi lưu lượng gần 0. R^2 được tính theo từng thực thể để phản ánh phần biến thiên so với trung bình của chính thực thể đó. Cả hai chỉ số chỉ tính trên `observed_mask = 1`.

$$\text{SMAPE} = \frac{100}{n} \sum_{i=1}^n \frac{2|\hat{y}_i - y_i|}{|y_i| + |\hat{y}_i| + \varepsilon}$$

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2 + \varepsilon}$$

3.4. Kết quả baseline cổ điển

Baseline cổ điển gồm Mean, Seasonal Naive 24/168 giờ, Moving Average 24/168 giờ; SARIMA được thực hiện ở cấp tổ chức để tạo mốc so sánh có thể kiểm tra.

Bảng 3.3. Kết quả baseline cổ điển theo cấp dữ liệu

Mô hình	Tổ chức: SMAPE median	Tổ chức: R^2 median	Mạng con: SMAPE median	Mạng con: R^2 median
Mean	94,19	-0,0753	87,74	-0,0698
SN-24	79,71	-0,3512	74,34	-0,5342
SN-168	78,69	-0,3035	76,36	-0,5970
MA-24	81,81	-0,0125	72,02	-0,0038
MA-168	86,69	-0,0672	76,45	-0,0388
SARIMA	75,81	0,0138	—	—

Ở cấp tổ chức, SARIMA có SMAPE median thấp hơn các baseline cổ điển còn lại. Ở cấp mạng con, MA-24 có SMAPE median thấp hơn các biến thể mùa vụ. R^2 median của nhóm cổ điển gần 0 hoặc âm, nên nhóm này chủ yếu là mốc tham chiếu mùa vụ.

3.5. Kết quả mô hình học sâu và ISPNet

Phần này trình bày LSTM, GRU, TCN, DLinear, Transformer, PatchTST, iTransformer và ISPNet. Ký hiệu $\pm$ là độ lệch chuẩn qua ba seed.

Bảng 3.4. Kết quả mô hình học sâu và ISPNet ở cấp tổ chức, horizon 24 giờ

Mô hình	SMAPE median ($\pm$ std)	SMAPE mean	R^2 median ($\pm$ std)	R^2 clip mean
LSTM	63,63 $\pm$ 0,20	63,47	0,2300 $\pm$ 0,0044	0,2304

Mô hình	SMAPE median ($\pm$ std)	SMAPE mean	R ² median ($\pm$ std)	R ² clip mean
GRU	63,13 $\pm$ 0,19	62,51	0,2416 $\pm$ 0,0119	0,2423
TCN	64,32 $\pm$ 0,35	63,64	0,1856 $\pm$ 0,0033	0,1657
DLinear	67,05 $\pm$ 0,09	65,33	0,1944 $\pm$ 0,0053	0,1981
Transformer	63,13 $\pm$ 0,42	62,23	0,2202 $\pm$ 0,0031	0,2175
PatchTST	65,56 $\pm$ 0,50	64,42	0,1949 $\pm$ 0,0044	0,1934
iTransformer	65,45 $\pm$ 0,42	63,86	0,2069 $\pm$ 0,0027	0,2111
ISPNet	62,39 $\pm$ 0,33	60,84	0,2643 $\pm$ 0,0138	0,2544

Ở cấp tổ chức, mốc 24 giờ, ISPNet có SMAPE median 62,39 $\pm$ 0,33 và R² median 0,2643 $\pm$ 0,0138; so với GRU, SMAPE thấp hơn 0,74 điểm phần trăm và R² cao hơn 0,0227.

Bảng 3.5. Kết quả mô hình học sâu và ISPNet ở cấp tổ chức, horizon 168 giờ

Mô hình	SMAPE median ($\pm$ std)	SMAPE mean	R ² median ($\pm$ std)	R ² clip mean
LSTM	72,36 $\pm$ 0,43	72,49	0,0984 $\pm$ 0,0427	0,0554
GRU	72,19 $\pm$ 1,38	72,94	0,1249 $\pm$ 0,0357	0,1035
TCN	72,42 $\pm$ 1,24	73,06	0,1253 $\pm$ 0,0095	0,1215
DLinear	73,54 $\pm$ 0,83	73,47	0,0392 $\pm$ 0,0017	0,0277
Transformer	70,85 $\pm$ 0,08	71,36	0,1379 $\pm$ 0,0177	0,1224
PatchTST	78,56 $\pm$ 1,35	79,59	-0,0128 $\pm$ 0,0114	-0,0554
iTransformer	74,76 $\pm$ 0,31	75,13	0,0254 $\pm$ 0,0044	0,0376
ISPNet	69,35 $\pm$ 0,52	67,75	0,1646 $\pm$ 0,0112	0,1575

Ở mốc 168 giờ, ISPNet có SMAPE median 69,35 $\pm$ 0,52, thấp hơn Transformer khoảng 1,50 điểm phần trăm.

Bảng 3.6. Kết quả mô hình học sâu và ISPNet ở cấp mạng con, horizon 24 giờ

Mô hình	SMAPE median ($\pm$ std)	SMAPE mean	R ² median ($\pm$ std)	R ² clip mean
LSTM	61,70 $\pm$ 0,55	63,00	0,0972 $\pm$ 0,0083	0,1436
GRU	60,62 $\pm$ 0,08	61,85	0,0954 $\pm$ 0,0103	0,1415
TCN	61,70 $\pm$ 0,40	63,51	0,0672 $\pm$ 0,0164	0,0890
DLinear	63,20 $\pm$ 0,18	65,65	0,0796 $\pm$ 0,0007	0,1227
Transformer	60,31 $\pm$ 0,29	61,89	0,0951 $\pm$ 0,0083	0,1389
PatchTST	62,53 $\pm$ 0,18	64,32	0,0685 $\pm$ 0,0046	0,1109
iTransformer	61,76 $\pm$ 0,25	63,55	0,0912 $\pm$ 0,0062	0,1429
ISPNet	58,81 $\pm$ 0,21	60,15	0,1146 $\pm$ 0,0023	0,1787

Ở cấp mạng con, mốc 24 giờ, Transformer là baseline gần nhất với SMAPE median 60,31 $\pm$ 0,29; ISPNet có SMAPE median 58,81 $\pm$ 0,21, thấp hơn 1,51 điểm phần trăm.

Bảng 3.7. Kết quả mô hình học sâu và ISPNet ở cấp mạng con, horizon 168 giờ

Mô hình	SMAPE median ($\pm$ std)	SMAPE mean	R ² median ($\pm$ std)	R ² clip mean
LSTM	67,59 $\pm$ 0,27	71,91	0,0131 $\pm$ 0,0040	0,0116
GRU	67,69 $\pm$ 0,42	72,40	0,0102 $\pm$ 0,0045	0,0093
TCN	67,50 $\pm$ 0,46	72,42	0,0172 $\pm$ 0,0032	0,0355
DLinear	68,46 $\pm$ 1,11	71,72	0,0019 $\pm$ 0,0079	0,0053
Transformer	67,18 $\pm$ 0,83	71,09	0,0186 $\pm$ 0,0074	0,0302
PatchTST	74,77 $\pm$ 0,60	78,71	-0,0217 $\pm$ 0,0055	-0,1007
iTransformer	69,66 $\pm$ 0,27	73,54	-0,0075 $\pm$ 0,0014	-0,0118
ISPNet	65,85 $\pm$ 0,32	67,84	0,0224 $\pm$ 0,0054	0,0551


Ở cấp mạng con, mốc 168 giờ, ISPNet có SMAPE median 65,85 $\pm$ 0,32 và R² median 0,0224 $\pm$ 0,0054. R² chênh lệch nhỏ hơn track tổ chức, nhưng SMAPE vẫn thấp hơn baseline gần nhất.

3.6. Đối chiếu trực tiếp với baseline gần nhất

Bảng đối chiếu rút gọn trình bày chênh lệch giữa ISPNet và baseline học sâu gần nhất theo từng lát cắt.

Bảng 3.8. Chênh lệch giữa ISPNet và baseline học sâu gần nhất

Track	Baseline gần nhất	SMAPE baseline	SMAPE ISPNet	Δ SMAPE	R ² baseline	R ² ISPNet	Δ R ²
Tổ chức, 24h	GRU	63,13 $\pm$ 0,19	62,39 $\pm$ 0,33	-0,74	0,2416 $\pm$ 0,0119	0,2643 $\pm$ 0,0138	+0,0227
Tổ chức, 168h	Transformer	70,85 $\pm$ 0,08	69,35 $\pm$ 0,52	-1,50	0,1379 $\pm$ 0,0177	0,1646 $\pm$ 0,0112	+0,0267
Mạng con, 24h	Transformer	60,31 $\pm$ 0,29	58,81 $\pm$ 0,21	-1,51	0,0951 $\pm$ 0,0083	0,1146 $\pm$ 0,0023	+0,0194
Mạng con, 168h	Transformer	67,18 $\pm$ 0,83	65,85 $\pm$ 0,32	-1,32	0,0186 $\pm$ 0,0074	0,0224 $\pm$ 0,0054	+0,0038



Hình 3.1. So sánh SMAPE median giữa baseline gần nhất và ISPNet

Dấu âm ở Δ SMAPE cho biết SMAPE của ISPNet thấp hơn baseline gần nhất ở cả cấp tổ chức, cấp mạng con và hai mốc dự báo.

Chênh lệch giữa ISPNet và baseline gần nhất có cùng xu hướng trên bốn thiết lập, phù hợp với vai trò của chuẩn hóa động theo cửa sổ và mật nà quan sát. Ở mốc 168 giờ, R^2 thấp hơn do khoảng dự báo dài, sai lệch pha theo giờ và biến động cục bộ; vì vậy SMAPE median được dùng làm thước đo chính cho sai số tương đối.

Phân tích theo nhóm thực thể chia chuỗi theo median n_bytes trên train. Ở cấp tổ chức 168 giờ, 80,5% thực thể có SMAPE thấp hơn baseline gần nhất; ở cấp mạng con 24 giờ, tỷ lệ này là 73,1%. Chênh lệch tập trung nhiều hơn ở nhóm traffic thấp.

Bảng 3.9. Phân tích theo nhóm thực thể so với baseline gần nhất

Track	Baseline	Nhóm có chênh lệch chính	Tỷ lệ thực thể SMAPE thấp hơn	Δ SMAPE median
Tổ chức, 24h	GRU	Traffic thấp	55,0%	-0,43 ở nhóm thấp
Tổ chức, 168h	Transformer	Traffic thấp và cao	80,5%	-3,26 ở nhóm thấp
Mạng con, 24h	Transformer	Traffic thấp/trung bình	73,1%	-0,96 ở nhóm thấp
Mạng con, 168h	Transformer	Traffic thấp	60,6%	-2,44 ở nhóm thấp

Kiểm định trên Δ SMAPE theo thực thể dùng cặp ISPNet và baseline gần nhất trong cùng track. Wilcoxon signed-rank có $p < 0,001$ ở ba track: tổ chức 168 giờ, mạng con 24 giờ và mạng con 168 giờ. Riêng tổ chức 24 giờ có sign test $p = 0,1077$ và Wilcoxon $p = 0,000524$.

3.7. Đối chiếu benchmark và chi phí triển khai

Đối chiếu benchmark chỉ dùng để đặt kết quả trong bối cảnh công bố gốc vì tiền xử lý, split, phạm vi thực thể và cấu hình mô hình không đồng nhất. Phân tích độ phức tạp tập trung vào cấp tổ chức 24 giờ.

Bảng 3.10. Đối chiếu benchmark và độ phức tạp chính

Nhóm đối chiếu	Mô hình / cấu hình	SMAPE median	R^2 median	Số tham số	Nhận xét
Benchmark gốc	GRU	128,10%	-0,1537	không đồng nhất	Mốc bối cảnh
Đồ án - baseline	GRU, horizon 24h	$63,13 \pm 0,19$	$0,2416 \pm 0,0119$	88.009	Baseline gần nhất ở track tổ chức 24h

Nhóm đối chiếu	Mô hình / cấu hình	SMAPE median	R ² median	Số tham số	Nhận xét
Đồ án - ISPNet	ISPNet, horizon 24h	$62,39 \pm 0,33$	$0,2643 \pm 0,0138$	88.009	RevIN/mask-aware không làm tăng tham số so với GRU cùng cấu hình

Theo cấu hình notebook, ISPNet giữ GRU hidden=64 và có 88.009 tham số ở cấp tổ chức, mốc 24 giờ. RevIN không có tham số học được; khác biệt chính nằm ở chuẩn hóa động và mặt nạ quan sát.

Khoảng cách với benchmark gốc không được xem là khác biệt mô hình thuần túy, vì benchmark có giao thức rộng hơn và có thể khác về chuỗi thừa, giá trị gần không, split và xử lý missing. Do đó, kết luận chính dựa trên baseline chạy lại trong cùng pipeline của báo cáo.

3.8. Ablation thành phần ISPNet

Ablation được thực hiện trên cấp tổ chức, mốc 24 giờ nhằm tách vai trò của chuẩn hóa động và đầu dự báo. Các biến thể dùng cùng giao thức tổng hợp qua thực thể.

Bảng 3.11. Ablation thành phần ISPNet trên track tổ chức, horizon 24 giờ

Biến thể	Thiết lập kiểm chứng	SMAPE median	R ² median	R ² clip mean
A - GRU	Không dùng RevIN	$63,13 \pm 0,19$	$0,2416 \pm 0,0119$	0,2423
B - GRU + Standard RevIN	Chuẩn hóa động không xét mask	$62,84 \pm 0,64$	$0,2704 \pm 0,0102$	0,2603
C - ISPNet	Mask-Aware RevIN	$62,39 \pm 0,33$	$0,2643 \pm 0,0138$	0,2544
D - ISPNet + FourierKAN	Mask-Aware RevIN + FourierKAN head	$62,80 \pm 0,22$	$0,2569 \pm 0,0052$	0,2470
E - ISPNet + ChebyKAN	Mask-Aware RevIN + ChebyKAN head	$62,59 \pm 0,10$	$0,2539 \pm 0,0008$	0,2423

Trong ablation, Mask-Aware RevIN có SMAPE thấp hơn các biến thể còn lại ở cấp tổ chức 24 giờ. Các biến thể KAN chưa cho mức giảm SMAPE trong phạm vi này; cấu hình chính giữ đầu dự báo tuyến tính.

3.9. Phân tích giai đoạn outage

Tập kiểm thử chứa outage 20/05/2024-10/06/2024, tương ứng 528 giờ. Giai đoạn này được tách riêng vì phản ánh trạng thái vận hành khác với phần test còn lại.

Bảng 3.12. Phân tích giai đoạn outage của ISPNet

Track	SMAPE tổng thể	SMAPE outage	Mức tăng	Nhận định
Tổ chức, 24h	62,39%	70,26%	+7,87 điểm %	SMAPE outage cao hơn SMAPE tổng thể 7,87 điểm phần trăm.
Tổ chức, 168h	69,35%	84,66%	+15,31 điểm %	SMAPE outage cao hơn SMAPE tổng thể 15,31 điểm phần trăm.
Mạng con, 24h	58,81%	66,29%	+7,49 điểm %	SMAPE outage cao hơn SMAPE tổng thể 7,49 điểm phần trăm.
Mạng con, 168h	65,85%	82,49%	+16,64 điểm %	SMAPE outage cao hơn SMAPE tổng thể 16,64 điểm phần trăm.

Kết quả outage cho thấy vẫn còn chênh lệch tổng thể, nên chưa đủ cơ sở để kết luận mô hình bao quát toàn bộ thay đổi phân phối. Hướng mở rộng gồm phát hiện thay đổi chế độ vận hành và mô hình hóa bất định dự báo.

3.10. Hạn chế và hướng phát triển

Phạm vi hiện tại tập trung vào lưu lượng byte; số luồng, số gói và hướng lưu lượng chưa đưa vào dự báo đa mục tiêu. Cấp IP chưa chọn làm phạm vi chính do độ thưa cao. Hướng phát triển gồm ràng buộc phân cấp tổ chức-mạng con, dự báo đa biến, đánh giá theo nhóm thực thể và phát hiện thay đổi chế độ trong outage.

Kết quả được diễn giải trong bốn track: tổ chức 24 giờ, tổ chức 168 giờ, mạng con 24 giờ và mạng con 168 giờ. Baseline và ISPNet dùng cùng tiền xử lý, split theo thời gian và tổng hợp qua ba seed; ba seed giảm phụ thuộc vào một lần huấn luyện nhưng chưa thay cho kiểm định thống kê chính thức.

Tỷ lệ thực thể có SMAPE thấp hơn baseline ở mục 3.6 là mô tả per-entity; sign test hoặc Wilcoxon trên ΔSMAPE là hướng kiểm định chặt hơn. Đối chiếu benchmark chỉ giữ vai trò tham chiếu do giao thức lọc thực thể, xử lý missing, split và huấn luyện không hoàn toàn đồng nhất.

Kết luận chương 3: ISPNet có SMAPE median thấp hơn baseline học sâu gần nhất ở bốn lát cắt chính. Phân tích theo nhóm thực thể cho thấy chênh lệch tập trung nhiều hơn ở nhóm traffic thấp; ablation liên hệ trực tiếp chênh lệch này với chuẩn hóa động có mặt nạ.

KẾT LUẬN

Báo cáo trình bày quy trình dự báo lưu lượng mạng ISP trên CESNET-TimeSeries24, gồm EDA, tiền xử lý, baseline và đánh giá ISPNet. Các quyết định chính gồm log1p, chuẩn hóa theo thực thể, observed_mask, đặc trưng lịch và chuẩn hóa động theo cửa sổ.

Ở cấp tổ chức, ISPNet có SMAPE median $62,39 \pm 0,33$ ở mốc 24 giờ và $69,35 \pm 0,52$ ở mốc 168 giờ. Ở cấp mạng con, các giá trị tương ứng là $58,81 \pm 0,21$ và $65,85 \pm 0,32$. Kết quả được tính theo trung bình ba seed và tổng hợp theo từng thực thể.

Ablation cho thấy Mask-Aware RevIN có SMAPE thấp hơn GRU không dùng RevIN và tránh đưa điểm khuyết vào thống kê chuẩn hóa. Mốc 168 giờ vẫn cần được xem xét thêm về phụ thuộc dài hạn trong dự báo một tuần.

Nội dung chính của đề án là liên kết EDA với tiền xử lý và mô hình gọn cho dữ liệu lưu lượng mạng thực. Hướng mở rộng gồm ràng buộc phân cấp giữa tổ chức và mạng con, dự báo đa biến và đánh giá chi phí triển khai trong môi trường vận hành.

TÀI LIỆU THAM KHẢO

- [1] Koumar, J., Smoleň, T., Jeřábek, K., & Čejka, T. (2025). Comparative Analysis of Deep Learning Models for Real-World ISP Network Traffic Forecasting. arXiv preprint arXiv:2503.17410.
- [2] Koumar, J., Hynek, K., Čejka, T., & Šiška, P. (2025). CESNET-TimeSeries24: Time Series Dataset for Network Traffic Anomaly Detection and Forecasting. *Scientific Data*, 12, 338.
- [3] Kureš, M., Koumar, J., & Hynek, K. (2025). CESNET TS-Zoo: A Library for Reproducible Analysis of Network Traffic Time Series. *Proceedings of the 21st International Conference on Network and Service Management (CNSM)*.
- [4] Liu, F., Farkiani, B., & Crowley, P. (2025). Time-Series Foundation Models for ISP Traffic Forecasting. arXiv preprint arXiv:2511.17529.
- [5] Kim, T., Kim, J., Tae, Y., Park, C., Choi, J. H., & Choo, J. (2022). Reversible Instance Normalization for Accurate Time-Series Forecasting against Distribution Shift. *International Conference on Learning Representations (ICLR)*.
- [6] Cho, K., Van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning Phrase Representations using RNN Encoder-Decoder for Statistical Machine Translation. *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*.
- [7] Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: Principles and Practice* (2nd ed.). OTexts: Melbourne, Australia.
- [8] Hochreiter, S., & Schmidhuber, J. (1997). Long Short-Term Memory. *Neural Computation*, 9(8), 1735-1780.
- [9] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*.
- [10] Bai, S., Kolter, J. Z., & Koltun, V. (2018). An Empirical Evaluation of Generic Convolutional and Recurrent Networks for Sequence Modeling. arXiv preprint arXiv:1803.01271.
- [11] Zeng, A., Chen, M., Zhang, L., & Xu, Q. (2023). Are Transformers Effective for Time Series Forecasting? *Proceedings of the AAAI Conference on Artificial Intelligence*, 37(9), 11121-11128.
- [12] Nie, Y., Nguyen, N. H., Sinthong, P., & Kalagnanam, J. (2023). A Time Series is Worth 64 Words: Long-term Forecasting with Transformers. *International Conference on Learning Representations (ICLR)*.

[13] Liu, Y., Hu, T., Zhang, H., Wu, H., Wang, S., Ma, L., & Long, M. (2024). iTransformer: Inverted Transformers Are Effective for Time Series Forecasting. International Conference on Learning Representations (ICLR).